

METAHEURÍSTICAS

2022-2023



- Tema 1. Introducción a las Metaheurísticas
- Tema 2. Modelos de Búsqueda: Entornos y Trayectorias vs Poblaciones
- Tema 3. Metaheurísticas Basadas en Poblaciones
- Tema 4: Algoritmos Meméticos
- Tema 5. Metaheurísticas Basadas en Trayectorias
- Tema 6. Metaheurísticas Basadas en Adaptación Social
- Tema 7. Aspectos Avanzados en Metaheurísticas
- Tema 8. Metaheurísticas Paralelas

METAHEURÍSTICAS

TEMA 7. ASPECTOS AVANZADOS EN METAHEURÍSTICAS

(El problema de la diversidad y exploración en la búsqueda)

1. INTENSIFICACIÓN VS DIVERSIFICACIÓN
2. ALGORITMOS GENÉTICOS. EXPLORACIÓN VS EXPLOTACIÓN.
ALGORITMOS CHC Y GADEGD
3. MÚLTIPLES SOLUCIONES. PROBLEMAS MULTIMODALES
4. COMENTARIOS FINALES

ASPECTOS AVANZADOS EN METAHEURÍSTICAS

(El problema de la diversidad y la exploración en la búsqueda)

Existen problemas abiertos a dos niveles

- a) tipología del problema a resolver mediante algoritmos metaheurísticos (múltiples soluciones, múltiples objetivos, restricciones, ...), y
- b) componentes de una MH que hace que tenga un mejor comportamiento (adaptación de parámetros, convergencia prematura, diversidad, ...)

La diversidad de la población/soluciones en el método de búsqueda (y la consiguiente exploración del espacio de búsqueda) y su equilibrio con la convergencia del algoritmo son esenciales para cualquier MH.

Vamos a estudiar el problema de la diversidad desde dos diferentes perspectivas:

- **Diversidad vs convergencia en el comportamiento del algoritmo de búsqueda**
- **Diversidad para encontrar múltiples soluciones para un problema**

METAHEURÍSTICAS

TEMA 7. ASPECTOS AVANZADOS EN METAHEURÍSTICAS

1. INTENSIFICACIÓN VS DIVERSIFICACIÓN
2. ALGORITMOS GENÉTICOS. EXPLORACIÓN VS EXPLOTACIÓN.
ALGORITMOS CHC Y GADEGD
3. MÚLTIPLES SOLUCIONES. PROBLEMAS MULTIMODALES
4. COMENTARIOS FINALES

INTENSIFICACIÓN VS DIVERSIFICACIÓN

El objetivo principal en el diseño de una Metaheurística es ser eficaz y efectiva explorando el espacio de búsqueda.

El primer sub-objetivo es tener una característica de búsqueda local (**explotación**), la cual es llamada **intensificación** del proceso de búsqueda.

El segundo sub-objetivo es tener una característica de búsqueda global (**exploración**), la cual se consigue con una apropiada **diversificación** del proceso de búsqueda.

Las versiones básicas de todas las metaheurísticas tienen un mecanismo de trabajo con la **intensificación y diversificación** del proceso de búsqueda.

INTENSIFICACIÓN VS DIVERSIFICACIÓN

Los mecanismos de intensificación y diversificación se pueden dividir en:

Intrínseco (básico): Mecanismos asociados al comportamiento básico del algoritmo.

Estratégicos: Técnicas y estrategias añadidas al procedimiento básico para mejorar el comportamiento global del algoritmo.

INTENSIFICACIÓN VS DIVERSIFICACIÓN

Los mecanismos de intensificación y diversificación básicos (intrínsecos) suelen actuar simultáneamente.

Los mecanismos estratégicos suelen aplicarse alternativamente, de forma oscilatoria.

Algunas metaheurísticas tienen un equilibrio estático entre intensificación y diversificación, mientras otras lo tienen dinámico.

Es interesante conocer los mecanismos básicos de las metaheurísticas estudiadas.

INTENSIFICACIÓN VS DIVERSIFICACIÓN

Consideraciones sobre las variantes básicas de las metaheurísticas:

Metaheurística	Intensificación Básica	Diversificación Básica
ES	Búsqueda Local	Modificación de T
BT	Búsqueda Local	Lista Tabú
GRASP	Búsqueda Local	Lista Candidatos
ILS	Búsqueda Local	Criterio aceptación y Perturbación
AGs	Selección y Reemplazamiento	Operadores Genéticos

INTENSIFICACIÓN VS DIVERSIFICACIÓN

Equilibrio Intensificación - Diversificación

ES Dinámico: + Div. - Int. HACIA -Div. +Int.

BT Estático: Tamaño Lista: +Tam. -Int. vs +Div. (vice)

ILS Depende del criterio de aceptación:
Intensificación si es Aceptación del mejor.
Diversificación - Ultimo óptimo local aceptado.

VNS Balance Oscilatorio

AGs Dinámico Diversidad: +Div. -Int. HACIA -Div. +Int.

El equilibrio correcto de intensificación-diversificación conduce a una metaheurística efectiva.

INTENSIFICACIÓN VS DIVERSIFICACIÓN

Mecanismos más sofisticados para el equilibrio oscilatorio:

ES: Reiniciando la Temperatura (esquema de enfriamiento no monótono)

BT: Cambiar dinámicamente el tamaño de la lista tabú
(*Reactive Tabu Search*)

AGs: Modificaciones del criterio de selección de cromosomas cuando se converge, introduciendo más diversidad (*soft-restart*), reinicialización, ...

OTROS MECANISMOS PARA OBTENER UN EQUILIBRIO OSCILATORIO:

HIBRIDACIÓN DE METAHEURÍSTICAS COMPONENTES
BÁSICAS/ESTRATÉGICAS

METAHEURÍSTICAS

TEMA 7. ASPECTOS AVANZADOS EN METAHEURÍSTICAS

1. INTENSIFICACIÓN VS DIVERSIFICACIÓN
2. ALGORITMOS GENÉTICOS. EXPLORACIÓN VS EXPLOTACIÓN.
ALGORITMOS CHC Y GADEGD
3. MÚLTIPLES SOLUCIONES. PROBLEMAS MULTIMODALES
4. COMENTARIOS FINALES

AGs: EXPLORACIÓN VS EXPLOTACIÓN

EXPLORACIÓN VERSUS EXPLOTACIÓN

Todo algoritmo de búsqueda necesita establecer un equilibrio entre dos factores aparentemente contrapuestos:

- **exploración del espacio de soluciones**, para realizar una búsqueda en amplitud, localizando así zonas prometedoras, y
- **explotación espacio de búsqueda**, para hacer una búsqueda en profundidad en dichas zonas, obteniendo así las mejores soluciones.

Los algoritmos genéticos son un tipo de algoritmo de búsqueda de propósito general, cuyas componentes pueden establecer un equilibrio entre exploración y explotación.

AGs: EXPLORACIÓN VS EXPLOTACIÓN

DIVERSIDAD VS. CONVERGENCIA EN AGs

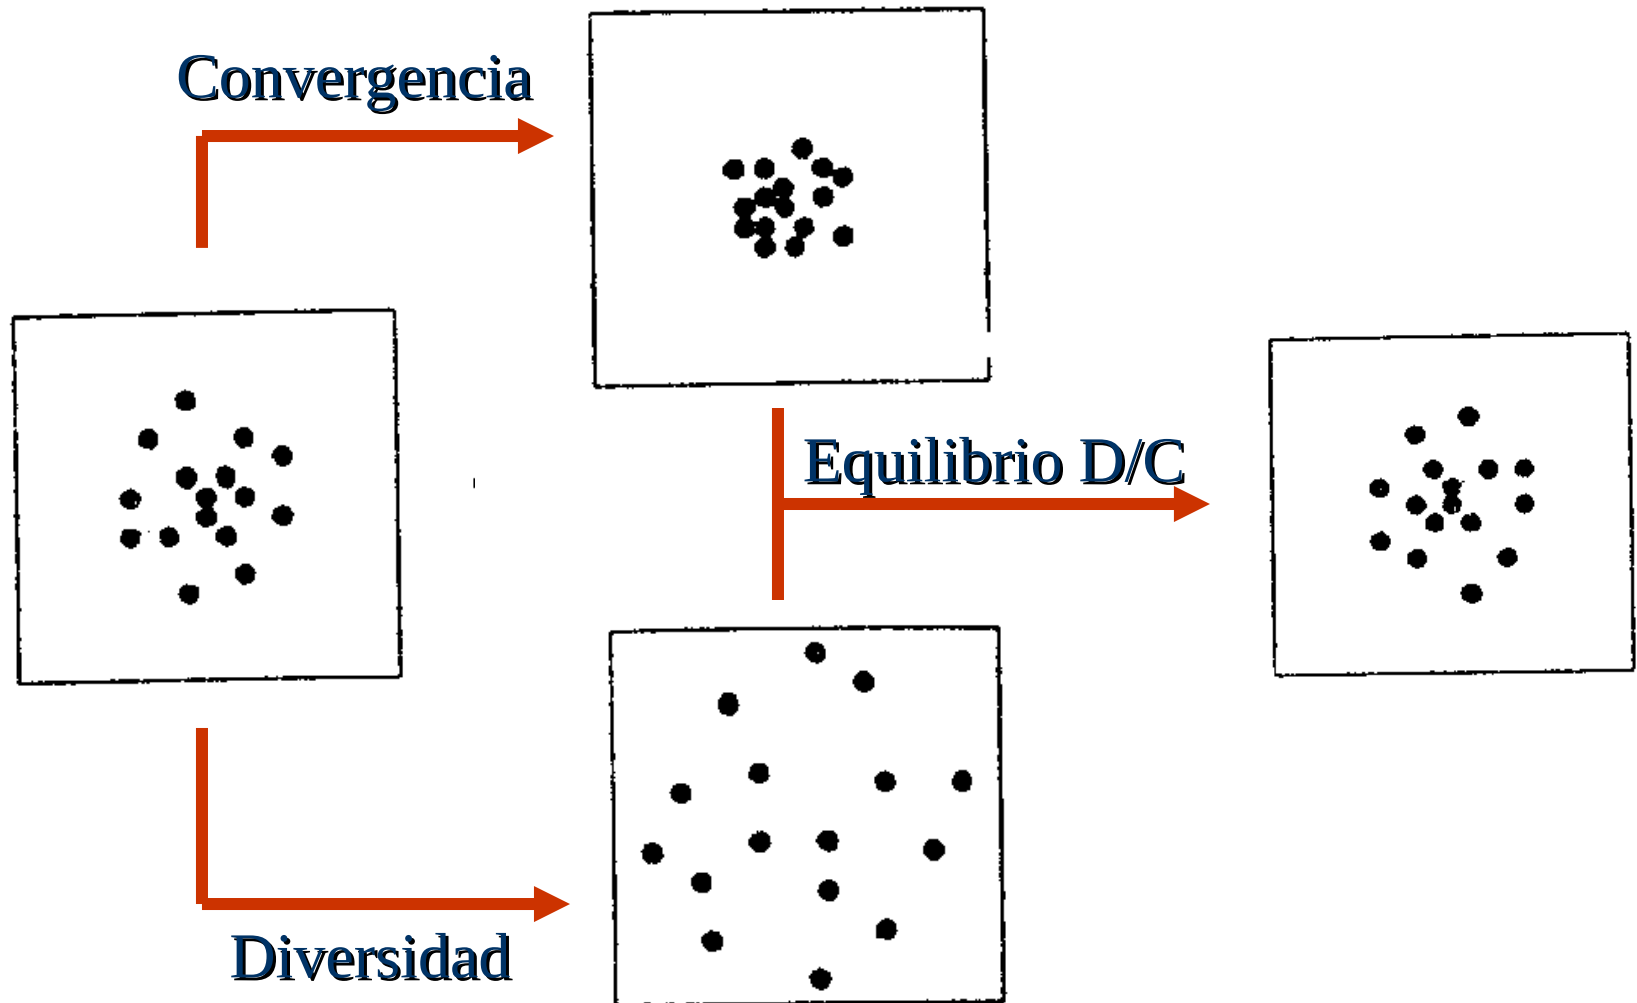
Dos factores contrapuestos influyen sobre la efectividad de un AG:

- **¿Cómo provocamos la Convergencia?:** Centrando la búsqueda en regiones prometedoras mediante la **presión selectiva, procesos de competición entre padres e hijos, ...**


La presión selectiva permite que los mejores individuos sean seleccionados para reproducirse. Es necesaria para que el proceso de búsqueda no sea aleatorio.

- **¿Cómo provocamos la Diversidad?:** Evitando la **convergencia prematura** (la rápida convergencia hacia zonas que no contienen el óptimo global), introduciendo diversidad en la población.

AGs: EXPLORACIÓN VS EXPLOTACIÓN



AGs: EXPLORACIÓN VS EXPLOTACIÓN

- La diversidad está asociada a las diferencias entre los cromosomas en la población
- Falta de diversidad genética = todos los individuos en la población son parecidos
- **Falta de diversidad**  **convergencia prematura a óptimos locales**
- En la práctica es irreversible. **Soluciones:**
 - **Inclusión de mecanismos de diversidad en la evolución** (MENCIONAREMOS 5 PROPUESTAS DE DIVERSIDAD, EXISTEN MUCHAS OTRAS. **SE MUESTRA EL ALGORITMO GADEGD**)
 - **Reinicialización cuando se produce convergencia prematura** (INCLUIDA EN EL MODELO CHC)

AGs: EXPLORACIÓN VS EXPLOTACIÓN

Algunas propuestas:

- **Diversidad con la Mutación**
- **Diversidad con el Cruce**
- **Separación Espacial**
- **Adaptación, Auto-adaptación, Metaevolución**
- **Estrategias de Reemplazamiento entre padres e hijos**
- **Uso de medidas de diversidad y estrategias para incluir diversidad en la población**

ALGORITMO DE EVOLUCIÓN CHC

CHC: Una de las primeras propuestas de AG que introduce un equilibrio entre diversidad y convergencia.

Actualmente es un modelo clásico.

**Introduce nuevos conceptos en los AG en los años 90:
Selección elitista (competición padres e hijos), diversidad en la selección para el cruce, reinicialización.**

Ref: *L.J. Eshelman, The CHC Adaptive Search Algorithm: how to Have Safe Search When Engaging in Nontraditional Genetic Recombination. Foundations of GENETIC ALGORITHMS (FOGA I, 1991), Morgan Kaufmann Publishers, San Mateo, 1991, 265-283.*

ALGORITMO DE EVOLUCIÓN CHC

Funcionamiento

Combina una selección elitista que preserva los mejores individuos que han aparecido hasta el momento con un operador de cruce que produce hijos muy diferentes a sus padres.

Introduce cuatro componentes novedosas:

- **Selección Elitista**
- **Cruce Uniforme HUX**
- **Prevención de Incesto**
- **Reinicialización**

ALGORITMO DE EVOLUCIÓN CHC

Selección Elitista. Selecciona los N mejores cromosomas entre padres e hijos.

Los N mejores elementos encontrados hasta el momento permanecerán en la población actual.

Cruce Uniforme (HUX). Intercambia exactamente la mitad de los alelos que son distintos en los padres.

Garantiza que los hijos tengan una distancia Hamming máxima a sus dos padres.

ALGORITMO DE EVOLUCIÓN CHC

Prevención de Incesto. Se forman $N/2$ parejas con los elementos de la población. Sólo se cruzan las parejas cuyos miembros difieren en un número determinado de bits (umbral de cruce).

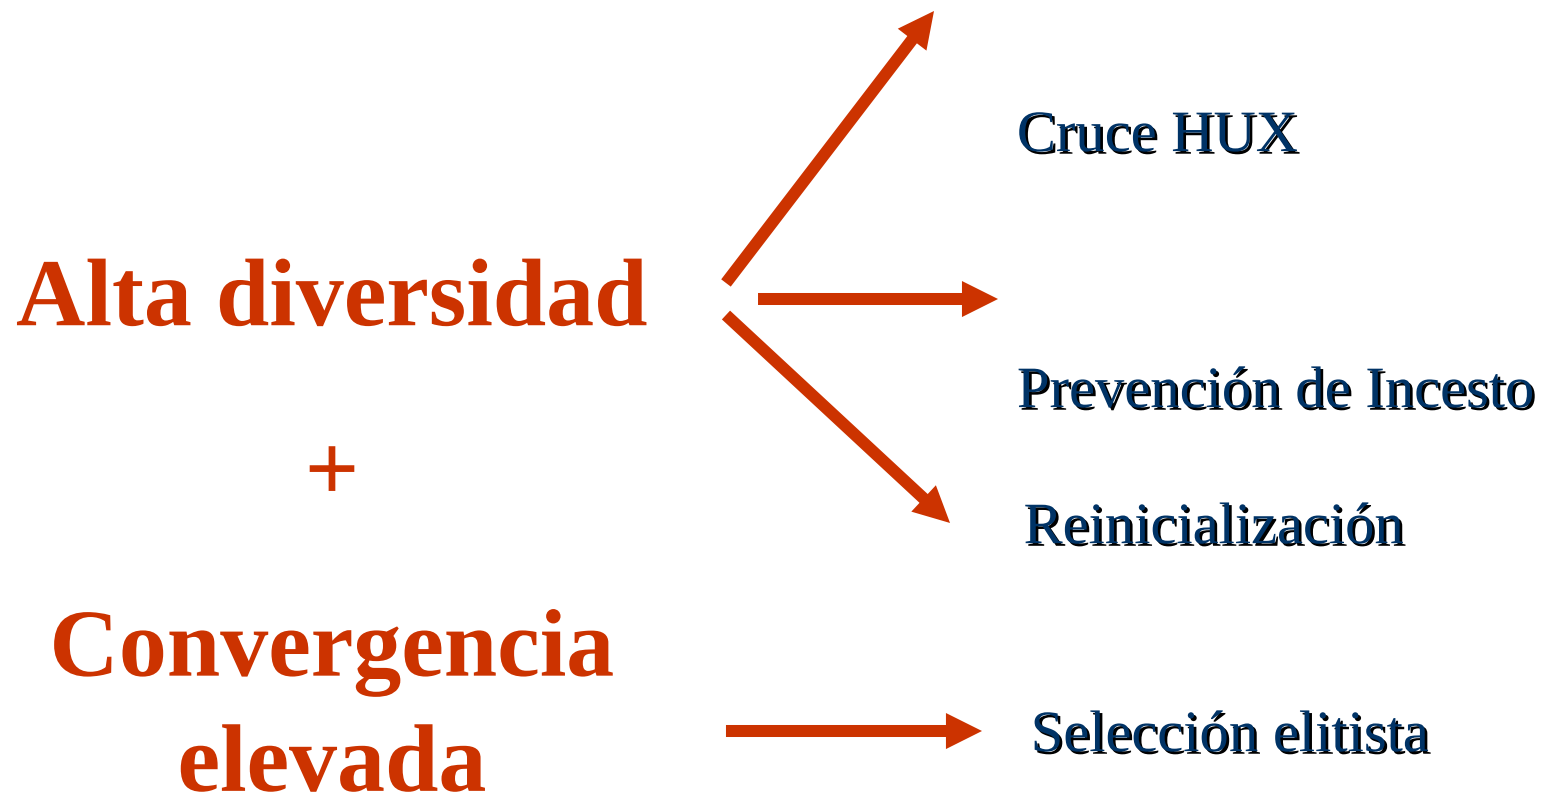
El umbral se inicializa a $H=L/4$ (L es la longitud del cromosoma). Si durante un ciclo no se crean descendientes mejores que los de la población anterior, al umbral de cruce se le resta 1.

Reinicialización. Cuando el umbral de cruce es menor que cero, la población se reinicializa: a) usando el mejor elemento como plantilla (35% de variación aleatoria) e incluyendo una copia suya, o b) manteniendo el mejor o parte de los mejores de la población y el resto se generan aleatoriamente.

CHC no aplica el operador de mutación.

ALGORITMO DE EVOLUCIÓN CHC

▪ Algoritmo CHC



ALGORITMO DE EVOLUCIÓN CHC

ESTRUCTURA DEL ALGORITMO

```
procedure CHC
begin
  t = 0;
  d = L/4;
  initialize P(t);
  evaluate structures in P(t);
  while termination condition not satisfied do
    begin
      t = t + 1;
      selectr C(t) from P(t-1);
      recombine structures in C(t) forming C'(t);
      evaluate structures in C'(t);
      selects P(t) from C'(t) and P(t-1);
      if P(t) equals P(t-1)
        d--;
      if d < 0
        begin
          diverge P(t);
          d = r × (1.0 - r) × L;
        end
      end
    end
  end.
end.
```

ALGORITMO DE EVOLUCIÓN CHC

Selección Elitista

procedure *select*,

begin

 copy all members of $P(t-1)$ to $C(t)$ in random order;

end.

procedure *select*,

begin

 form $P(t)$ from $P(t-1)$

 by replacing the worst members of $P(t-1)$

 with the best members of $C'(t)$

 until no remaining member of $C'(t)$

 is any better than any remaining member of $P(t-1)$;

end.

ALGORITMO DE EVOLUCIÓN CHC

Cruce HUX y Prevención del Incesto

```
procedure recombine
begin
  for each of the  $M/2$  pairs of structures in  $C(t)$ 
  begin
    determine the Hamming_distance
    if  $(\text{Hamming\_distance}/2) > d$ 
      swap half the differing bits at random;
    else
      delete the pair of structures from  $C(t)$ ;
  end
end.
```


ALGORITMO DE EVOLUCIÓN CHC

Reinicialización

procedure *diverge*

begin

 replace $P(t)$ with M copies of the best member of $P(t-1)$;

 for all but one member of $P(t)$

begin

 flip $r \times L$ bits at random;

evaluate structure;

end

end.

AGs: EXPLORACIÓN VS EXPLOTACIÓN

Algunas propuestas:

- Diversidad con la Mutación
- Diversidad con el Cruce
- Separación Espacial
- Adaptación, Auto-adaptación, Metaevolución
- Estrategias de Reemplazamiento entre padres e hijos
- **Uso de medidas de diversidad y estrategias para incluir diversidad en la población**

Exploración vs explotación: Ejemplo de algoritmo híbrido

GADEGD: genetic algorithm with diversity equilibrium based on greedy diversification

GADEGD utiliza medidas de diversidad y estrategias para incluir diversidad en la población


Algoritmo Genético con Diversificación Voraz y Equilibrio entre Exploración y Explotación

A. Herrera, F. Herrera

<https://arxiv.org/abs/1702.03594>

Genetic and Memetic Algorithm with Diversity Equilibrium based on Greedy Diversification

Motivación: Diversidad en la población




Diversidad del algoritmo genético standar

$$d: S \times S \rightarrow \mathbb{R}^+ \cup \{0\}:$$

$$D(t) = \frac{\sum_{s, s' \in P(t)} d(s, s')}{(n-1)n}$$

Algoritmo Genético Equilibrado con Diversificación Voraz



Propuesta: Diversificación de la población

Algoritmo Genético Generacional con Diversificación

$t \leftarrow 0;$

inicializar $P(t)$;

While (**Not** *CondiciónFinal*) **do**

$t \leftarrow t + 1;$

$P(t) \leftarrow \text{crearNuevaGeneración}(P(t-1));$

diversificar($P(t)$);

endwhile

Diversificación voraz de la población

Procedimiento *diversificarVoraz*($P(t)$, $g(.)$):

For s **in** $P(t)$ **do**

if ($\exists s' \in P(t) \setminus \{s\}$ *t.q.* $g(s) = g(s')$) **then**

$s \leftarrow$ *generarSoluciónVorazAleatorizada*();

endif

endfor

Función *generarSoluciónVorazAleatorizada*()

Solución $\leftarrow \{\}$;

While (No esté construida la solución) **do**

CrearLRC(LRC);

$x \leftarrow$ *seleccionarElementoAleatorio*(LRC);

Solución \leftarrow *Solución* $\cup \{x\}$;

adaptarFunciónVoraz(x);

endwhile

Diversificación voraz de la población

El uso del mecanismo de diversificación produce de por sí una severa mejora en el AG clásico.

<i>Problema</i>	<i>Óptimo</i>	<i>AG</i>	<i>AG+DV</i>
eil51	426	441	433.2
berlin52	7542	8123.03	7561.03
st70	675	711.767	694.2
eil76	538	570.767	559.1
pr76	108159	119699	113510
kroA100	21282	22769.7	21747.8
rd100	7910	8415.43	8054.83
eil101	629	672.433	657.167
lin105	14379	14888.2	14540.3
ch150	6528	6887.63	6676.47
rat195	2323	2524.67	2479
d198	15780	17235.3	16739.7
ts225	126643	135632	130436
a280	2579	2871.77	2847.17
lin318	42029	46927.4	46395
fl417	11861	13138.8	12741
pcb442	50778	58241.2	59163.1
rat575	6773	7877.9	7966.1
		2 / 16	16 / 2

Tamaño población: 60
Tiempo ejecución: 0.1xN
18 instancias TSP

Resultados con GRASP y SA con menos tiempo de ejecución:

Problema Eil101 – GRASP + LS – 300 iteraciones – 677 -1.37 segs

Problema Eil101 – SA . 665.68 – 1.3 seg – 10000 iteraciones (1000 soluciones bucle interno)

Algoritmo Genético Equilibrado con Diversificación Voraz

La sinergia entre este mecanismo y los demás operadores del algoritmo es ampliamente mejorable.

Se propone un nuevo modelo de AG con las siguientes características:

- 1. Mecanismo de selección de padres que potencie la diversidad en el cruce llamado selección aleatoria adyacente.**
- 2. Probabilidad de cruce 1.**
- 3. Se elimina el uso del operador de mutación.**
- 4. Aplicación del concepto de competición entre padres e hijos para aumentar la presión ejercida sobre la población.**
- 5. Diversificación voraz de la población en cada iteración del algoritmo.**


Algoritmo Genético Equilibrado con Diversificación Voraz

Algoritmo Genético Equilibrado con Diversificación Voraz

```
 $t \leftarrow 0;$   
inicializar  $P(t);$   
While (Not CondiciónFinal) do  
     $t \leftarrow t + 1;$   
     $P(t) \leftarrow \text{crearNuevaPoblación}(P(t-1));$   
    diversificarVoraz( $P(t), Id(.)$ );  
endwhile
```

```
    Función crearNuevaPoblación( $P(t)$ )  
         $P(t+1) \leftarrow \emptyset;$   
        ordenarAleatoriamente( $P(t)$ );  
        for  $i$  in  $\{0, 1, \dots, \text{size}(P(t)) - 1\}$  do  
             $\text{padre1} \leftarrow \text{elemento}(P(t), i);$   
             $\text{padre2} \leftarrow \text{elemento}(P(t), (i+1) \% \text{size}(P(t)));$   
             $\text{hijo} \leftarrow \text{cruce}(\text{padre1}, \text{padre2});$   
            if padre1 es mejor que hijo then  
                 $P(t+1) \leftarrow P(t+1) \cup \text{padre1};$   
            else  
                 $P(t+1) \leftarrow P(t+1) \cup \text{hijo};$   
            endif  
        endfor  
        return  $P(t+1);$ 
```

Algoritmo Genético Equilibrado con Diversificación Voraz



Diversidad del AGEDV y AG.
TSP Problema Berlin52

El algoritmo AGEDV mantiene la diversidad de la población en un alto valor gracias a la diversificación voraz y el funcionamiento del mismo, que permite trabajar con cromosomas de calidad en diferentes puntos del espacio de soluciones.

Algoritmo Genético Equilibrado con Diversificación Voraz

TABLA II

AGEDV CON $g = Id$ y $g = f$. TIEMPO = 0.1N SEGS.

<i>Problema</i>	<i>Óptimo</i>	<i>Calidad Media</i>		<i>Porcentaje de Soluciones Voraces</i>	
		<i>AGEDV</i> <i>g=Id</i>	<i>AGEDV</i> <i>g=f</i>	<i>AGEDV</i> <i>g=Id</i>	<i>AGEDV</i> <i>g=f</i>
eil51	426	427.267	428.4	5.36748	10.1318
berlin52	7542	7572.57	7572.57	5.08438	5.23617
st70	675	682.067	686.433	4.62881	7.36705
eil76	538	549.5	549.9	4.27079	8.90469
pr76	108159	109395	109503	4.55236	4.57542
kroA100	21282	21352.5	21384.6	4.90119	4.91509
rd100	7910	7919.47	7926.5	4.56272	4.70796
eil101	629	633.3	634.233	5.28149	7.87105
lin105	14379	14430.5	14423.3	4.82928	4.8212
ch150	6528	6578.67	6586.03	4.30821	4.49253
rat195	2323	2386.83	2400.87	3.88133	4.52266
d198	15780	16053.9	16076.2	4.18145	4.261
ts225	126643	127427	127355	2.7799	2.59045
a280	2579	2704.5	2727.53	4.09656	4.68289
lin318	42029	43739.5	43843.7	3.97038	4.03494
fl417	11861	12303.9	12286	4.01814	4.09853
pcb442	50778	55502	55477	2.72923	2.74129
rat575	6773	7670.97	7712.5	2.08298	2.21214
		14 / 4	5 / 13		

La diversificación a nivel del espacio de soluciones aporta mejor equilibrio que a nivel de función objetivo.

Algoritmo Genético Equilibrado con Diversificación Voraz

La reinicialización voraz
(utilizando greedy
aleatorio para
reinicializar)
aporta calidad en los
algoritmos estudiados

TABLA III
CHC Y MICRO-AG CON REINICIALIZACIÓN
ALEATORIA Y VORAZ (TIEMPO = $0.1 * N$)

<i>Problema</i>	<i>Óptimo</i>	<i>Calidad Media</i>			
		<i>CHC</i>	<i>CHC R.Voraz</i>	<i>MicroGA</i>	<i>MicroGA R.Voraz</i>
eil51	426	496.8	443.933	447.267	432.267
berlin52	7542	8041.8	7633.1	8053.27	7588.1
st70	675	889	730.8	743.967	689.9
eil76	538	665.2	574	586.933	554.767
pr76	108159	114084	109572	116626	111017
kroA100	21282	24010.4	21377.7	25627.2	21689.2
rd100	7910	9496.23	7998.23	9418.3	8010.03
eil101	629	827.7	686.267	729.433	634.567
lin105	14379	19445.4	14426.4	16827.7	14511.4
ch150	6528	9311.93	6763.63	9294.63	6626.73
rat195	2323	3515.8	2431.4	3566.53	2430.53
d198	15780	21395.6	16603.7	22493.2	16387.3
ts225	126643	214322	133175	251757	129840
a280	2579	5109.53	2891.43	5496.5	2791.93
lin318	42029	82239.7	43917.3	107959	44886.4
fl417	11861	32020.3	12937	60670.7	12674.2
pcb442	50778	117600	57568.3	174361	58950.6
rat575	6773	18170.7	7773.43	26568	8024.4

Algoritmo Genético Equilibrado con Diversificación Voraz

Comportamiento de la propuesta en comparación con algoritmos del estado del arte

TABLA IV
AG CLÁSICO, CHC, MICRO-GA Y AGEDV

Problema	Óptimo	Calidad Media			
		AG	CHC <i>R. Voraz</i>	<i>MicroGA</i> <i>R. Voraz</i>	AGEDV
eil51	426	441	<u>443.933</u>	432.267	427.267
berlin52	7542	<u>8123.03</u>	7633.1	7588.1	7572.57
st70	675	711.767	<u>730.8</u>	689.9	682.067
eil76	538	570.767	<u>574</u>	554.767	549.5
pr76	108159	<u>119699</u>	109572	111017	109395
kroA100	21282	<u>22769.7</u>	21377.7	21689.2	21352.5
rd100	7910	<u>8415.43</u>	7998.23	8010.03	7919.47
eil101	629	672.433	<u>686.267</u>	634.567	633.3
lin105	14379	<u>14888.2</u>	14426.4	14511.4	14430.5
ch150	6528	<u>6887.63</u>	6763.63	6626.73	6578.67
rat195	2323	<u>2524.67</u>	2431.4	2430.53	2386.83
d198	15780	<u>17235.3</u>	16603.7	16387.3	16053.9
ts225	126643	<u>135632</u>	133175	129840	127427
a280	2579	2871.77	<u>2891.43</u>	2791.93	2704.5
lin318	42029	<u>46927.4</u>	43917.3	44886.4	43739.5
fl417	11861	<u>13138.8</u>	12937	12674.2	12303.9
pcb442	50778	58241.2	57568.3	<u>58950.6</u>	55502
rat575	6773	7877.9	7773.43	<u>8024.4</u>	7670.97
		0 / 11	1 / 5	0 / 2	17 / 0

La sinergia entre este mecanismo y los demás operadores del algoritmo es ampliamente mejorable.

Se propone un nuevo modelo de AG con las siguientes características:

1. Mecanismo de selección de padres que potencie la diversidad en el cruce llamado selección aleatoria adyacente.
2. Probabilidad de cruce 1.
3. Se elimina el uso del operador de mutación.
4. Aplicación del concepto de competición entre padres e hijos para aumentar la presión ejercida sobre la población.
5. Diversificación voraz de la población en cada iteración del algoritmo.

Algoritmo Genético Equilibrado con Diversificación Voraz






Figure 3: Convergence: GADEGD vs CHC with G.R. vs Micro-GA with G.R.

Convergencia: AG vs Micro-AG con R. Voraz vs CHC con R. Voraz vs AGEDV

Algoritmo Genético Equilibrado con Diversificación Voraz



Diversidad: AG vs Micro-AG con R. Voraz vs
con R. Voraz vs AGEDV

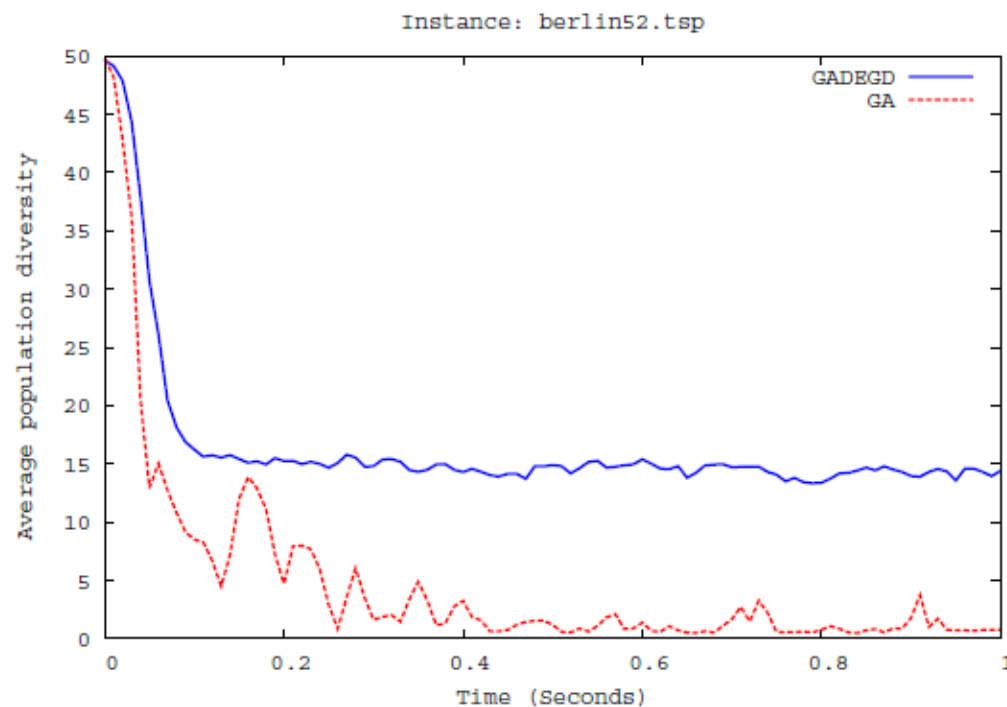


Figure 2: Diversity: GADEGD vs generational genetic algorithm (Algorithm 2)

Algoritmo Genético Equilibrado con Diversificación Voraz

TABLA VI

ALGORITMOS CON O SIN DIVERSIFICACIÓN

<i>Problema</i>	<i>Óptimo</i>	<i>Calidad Media</i>			
		<i>AG</i>	<i>AG+DV</i>	<i>AGEDV</i>	<i>AGE</i>
eil51	426	441	433.2	427.267	<u>768.9</u>
berlin52	7542	8123.03	7561.03	7572.57	<u>13100.2</u>
st70	675	711.767	694.2	682.067	<u>1578.37</u>
eil76	538	570.767	559.1	549.5	<u>1155.9</u>
pr76	108159	119699	113510	109395	<u>252397</u>
kroA100	21282	22769.7	21747.8	21352.5	<u>72659.5</u>
rd100	7910	8415.43	8054.83	7919.47	<u>24980</u>
eil101	629	672.433	657.167	633.3	<u>1628.1</u>
lin105	14379	14888.2	14540.3	14430.5	<u>50828.4</u>
ch150	6528	6887.63	6676.47	6578.67	<u>26031.4</u>
rat195	2323	2524.67	2479	2386.83	<u>10503.4</u>
d198	15780	17235.3	16739.7	16053.9	<u>64996.9</u>
ts225	126643	135632	130436	127427	<u>793764</u>
a280	2579	2871.77	2847.17	2704.5	<u>16773</u>
lin318	42029	46927.4	46395	43739.5	<u>301153</u>
fl417	11861	13138.8	12741	12303.9	<u>188661</u>
pcb442	50778	58241.2	59163.1	55502	<u>418762</u>
rat575	6773	7877.9	7966.1	7670.97	<u>58253.8</u>
		0 / 0	1 / 0	17 / 0	0 / 18

Análisis de
componentes

(AGE es el algoritmo
evolutivo con las
componentes de
AGEDV sin DV)

Algoritmo Genético Equilibrado con Diversificación Voraz


TABLA VII
COMPARACIÓN CON OTROS MECANISMOS DE PRESIÓN
Y SELECCIÓN

<i>Problema</i>	<i>Calidad Media</i>		
	<i>AGEDV</i>	<i>AGEDV sin Competición P.H Y con elitismo</i>	<i>AGEDV Con Selección <u>PorTorneo</u></i>
eil51	427.267	<u>1286.37</u>	439.467
berlin52	7572.57	<u>22970.9</u>	7902.8
st70	682.067	<u>2896.23</u>	697.2
eil76	549.5	<u>2134.83</u>	569.4
pr76	109395	<u>480546</u>	120715
kroA100	21352.5	<u>121662</u>	22749.8
rd100	7919.47	<u>47625</u>	8324.43
eil101	633.3	<u>2818.3</u>	648.233
lin105	14430.5	<u>95986.2</u>	14633.2
ch150	6578.67	<u>47638.1</u>	6940.2
rat195	2386.83	<u>19867.6</u>	2534.37
d198	16053.9	<u>163905</u>	16980.9
ts225	127427	<u>130959</u>	134465
a280	2704.5	<u>29621.5</u>	2852.07
lin318	43739.5	<u>518669</u>	48773
fl417	12303.9	<u>464044</u>	12852.8
pcb442	55502	<u>717566</u>	60669.3
rat575	7670.97	<u>95117</u>	8057.63
	18 / 0	0 / 18	0 / 0

Análisis de otros
mecanismos de
presión y
selección

Nos planeamos un algoritmo más eficaz

Eficacia: Algoritmos Meméticos – Igualmente falta de diversidad en la población



Algoritmo Memético Equilibrado con Diversificación Voraz





Figura : Diversidad en la población de los algoritmos AM y AMEDV.

Algoritmo Memético Equilibrado con Diversificación Voraz

Pseudo-código de un algoritmo memético



Algoritmo 3 Algoritmo memético equilibrado con diversificación voraz

- 1: Inicializar la población P con un algoritmo voraz aleatorizado.
 - 2: **while not** CriterioParada **do**
 - 3: Aplicar una iteración del algoritmo AGEDV a P (Algoritmo 2).
 - 4: Aplicar la búsqueda local al mejor individuo de P' no mejorado previamente (si existe).
 - 5: **fin while**
-

Análisis Experimental: Frente a AM, GRASP, IG

**Comparación con otras
heurísticas basadas en búsqueda
local: Algoritmo memético, GRAPS
e Iterated Greedy**

Problema Óptimo		Calidad Media			
		AMEDV	AM	GRASP	IG
eil51	426	426.167	<u>433.8</u>	432.133	432.1
berlin52	7542	7542	7628.8	<u>7670.43</u>	7665.73
st70	675	675	689.567	<u>692.433</u>	692.133
eil76	538	538	548	<u>551.867</u>	550.733
pr76	108159	108159	109382	110083	<u>110544</u>
kroA100	21282	21282	21408	21469.2	<u>21475.8</u>
rd100	7910	7910	7951.87	8033.37	<u>8061.1</u>
eil101	629	629	641.533	647.833	<u>648.267</u>
lin105	14379	14379	14482.7	14551.6	<u>14569.7</u>
ch150	6528	6541.5	6575.73	6642.1	<u>6671.73</u>
rat195	2323	2329.4	2349.37	<u>2373.23</u>	2369.23
d198	15780	15801.4	15883.3	<u>16015</u>	15981.3
ts225	126643	126794	129022	129865	<u>130035</u>
a280	2579	2582.8	2637.43	2659.3	<u>2660.7</u>
lin318	42029	42300	42827.2	43068.8	<u>43157.7</u>
fl417	11861	11940.8	12041.1	<u>12156.8</u>	12130.5
pcb442	50778	51257.1	52319.9	<u>52589.2</u>	52585
rat575	6773	6874.23	6924.53	6944.6	<u>6951.93</u>

Algoritmo Genético Equilibrado con Diversificación Voraz

TABLA VII

COMPARACIÓN CON OTROS MECANISMOS DE PRESIÓN

Y SELECCIÓN

Problema	Calidad Media						
	AGEDV	Problema Óptimo		Calidad Media			
				AMEDV AM	GRASP IG		
eil51	427.267	eil51	426	426.167	433.8	432.133	432.1
berlin52	7572.57	berlin52	7542	7542	7628.8	7670.43	7665.73
st70	682.067	st70	675	675	689.567	692.433	692.133
eil76	549.5	eil76	538	538	548	551.867	550.733
pr76	109395	pr76	108159	108159	109382	110083	110544
kroA100	21352.5	kroA100	21282	21282	21408	21469.2	21475.8
rd100	7919.47	rd100	7910	7910	7951.87	8033.37	8061.1
eil101	633.3	eil101	629	629	641.533	647.833	648.267
lin105	14430.5	lin105	14379	14379	14482.7	14551.6	14569.7
ch150	6578.67	ch150	6528	6541.5	6575.73	6642.1	6671.73
rat195	2386.83	rat195	2323	2329.4	2349.37	2373.23	2369.23
d198	16053.9	d198	15780	15801.4	15883.3	16015	15981.3
ts225	127427	ts225	126643	126794	129022	129865	130035
a280	2704.5	a280	2579	2582.8	2637.43	2659.3	2660.7
lin318	43739.5	lin318	42029	42300	42827.2	43068.8	43157.7
fl417	12303.9	fl417	11861	11940.8	12041.1	12156.8	12130.5
pcb442	55502	pcb442	50778	51257.1	52319.9	52589.2	52585
rat575	7670.97	rat575	6773	6874.23	6924.53	6944.6	6951.93
	18 / 0						

Conclusiones: AMEDV

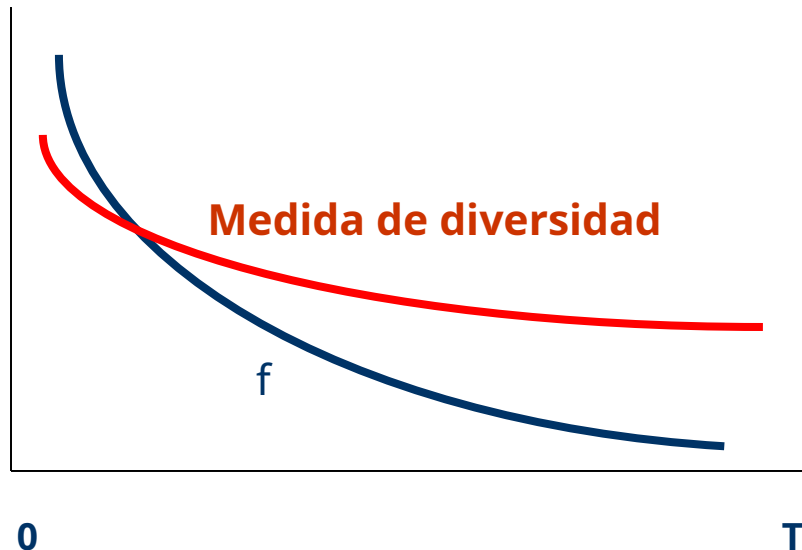
El funcionamiento del algoritmo AMEDV se debe al proceso de diversificación voraz, ideado para solucionar el problema de la diversidad de los algoritmos genéticos.

El buen comportamiento del modelo pone de manifiesto la necesidad de mantener la diversidad de la población en los algoritmos meméticos así como el aprovechamiento de la misma a través de los demás operadores para obtener un buen equilibrio entre exploración y explotación.

AGs: DIVERSIDAD VS. CONVERGENCIA

Comentarios Finales

Este es un problema de continuo estudio.



¿Cómo conseguir que f converja y que la diversidad se mantenga en un rango aceptable para evitar la convergencia prematura?

METAHEURÍSTICAS


TEMA 7. ASPECTOS AVANZADOS EN METAHEURÍSTICAS

1. INTENSIFICACIÓN VS DIVERSIFICACIÓN
2. ALGORITMOS GENÉTICOS. EXPLORACIÓN VS EXPLOTACIÓN.
ALGORITMOS CHC Y GADEGD
3. MÚLTIPLES SOLUCIONES. PROBLEMAS MULTIMODALES (Niching Genetic Algorithms)
4. COMENTARIOS FINALES

Diversidad para encontrar múltiples soluciones para un problema


PROBLEMAS MULTIMODALES

Muchos problemas interesantes tienen más de una solución localmente óptima.





PROBLEMAS MULTIOBJETIVO

Muchos problemas interesantes tienen múltiples objetivos, y la solución es un frente de Pareto



PROBLEMAS MULTIMODALES



- Muchos problemas interesantes tienen más de una solución localmente óptima.
- En la resolución del problema se desea obtener varios de esos óptimos locales o globales.
- Son problemas que tienen múltiples óptimos locales o múltiples óptimos globales (múltiples soluciones al problema).



PROBLEMAS MULTIMODALES


- Ejemplo: Encontrar el máximo de la función $z = f(x, y)$

$$z = f(x, y) = 3*(1-x)^2*\exp(-(x^2) - (y+1)^2) - 10*(x/5 - x^3 - y^5)*\exp(-x^2-y^2) - 1/3*\exp(-(x+1)^2 - y^2).$$





EVOLUCIÓN EN PROBLEMA MULTIMODALES

- Se comienza con una población inicial que proporciona un muestreo aleatorio del espacio solución.
- El proceso evolutivo suele provocar la convergencia de toda la población a una zona restringida del espacio de búsqueda, abandonando la exploración del resto de óptimos locales **deriva genética**.




Población inicial (Gen 0)



Después de 10 generaciones

EVOLUCIÓN EN PROBLEMAS MULTIMODALES


1.- Las búsquedas se focalizan en único punto



EVOLUCIÓN EN PROBLEMAS MULTIMODALES

1.- Las búsquedas se focalizan en único punto

2.- Se pierde diversidad




EVOLUCIÓN EN PROBLEMAS MULTIMODALES

1.- Las búsquedas se focalizan en único punto

2.- Se pierde diversidad

3.- Converge prematuramente




EVOLUCIÓN EN PROBLEMAS MULTIMODALES

1.- Las búsquedas se focalizan en único punto

2.- Se pierde diversidad

3.- Converge prematuramente

4.- No obtienen todos los óptimos




EVOLUCIÓN EN PROBLEMAS MULTIMODALES

1.- Las búsquedas se focalizan en único punto

2.- Se pierde diversidad

3.- Converge prematuramente

4.- No obtienen todos los óptimos



EVOLUCIÓN EN PROBLEMAS MULTIMODALES

El Objetivo para obtener múltiples soluciones ante problemas multimodales es preservar la diversidad en la población



Para permitir la búsqueda simultánea en diferentes áreas tenemos que limitar la competencia de las soluciones dentro de estas áreas y no fuera de ellas



La propuesta es utilizar algoritmos de nichos o multimodales

EVOLUCIÓN EN PROBLEMAS MULTIMODALES


Se introduce el concepto de nichos.

Los AGs evolucionan una población que permita tener soluciones en diferentes zonas del espacio de búsqueda (nichos) (evolución con nichos).


**Manejo de problemas con
Múltiples “óptimos-locales”/“soluciones”**

B. Sareni, L. Krähenbühk, Fitness Sharing and Niching Methods Revisited. IEEE Transactions on Evolutionary Computation, Vol. 2, No. 3, Septiembre 1998, 97-106.

EVOLUCIÓN EN PROBLEMAS MULTIMODALES



Varios óptimos globales
Evolución sin nichos y sin mutación




Varios óptimos locales
Evolución sin nichos y sin mutación


Se produce la convergencia a cualquier óptimo, debido fundamentalmente al efecto denominado deriva genética.

Propuesta alternativa: AG con nichos – AG Multimodales

EVOLUCIÓN EN PROBLEMAS MULTIMODALES



Varios óptimos globales
Evolución con nichos y sin mutación



Varios óptimos locales
Evolución con nichos y sin mutación

Se produce la convergencia a varios óptimos mediante técnicas de nichos.

AG MULTIMODALES (Nicheing GAs)

MODELOS DE AGs MULTIMODALES

- **Espaciales:** Formación de diferentes nichos en las poblaciones de una misma ejecución del AG.

Dos ejemplos:

- Fitness Sharing (Penalización de la calidad)
- Clearing (Limpieza en la población)
- Species competition (Conservación de especies)
- Crowding (Agrupamiento)

- **Temporales:** Formación de diferentes nichos a lo largo de diferentes ejecuciones del AG.

- **Sequential (Método secuencial):** Beasley, D.; Bull, D.R. y Martin, R.R. (1993). "A sequential niche technique for multimodal function optimization". *Evolutionary Computation*, Vol. 1(2): 101-125.

Revisión de algoritmos clásicos:

E. Pérez, M. Posada, [F. Herrera](#), Analysis of New Niching Genetic Algorithms for Finding Multiple Solutions in the Job Shop Scheduling. *Journal of Intelligent Manufacturing* 23:3 (2012) 341-356, [doi: 10.1007/s10845-010-0385-4](https://doi.org/10.1007/s10845-010-0385-4)

MODELOS DE AGs MULTIMODALES

■ Clearing (Aclarado):

Proceso: La selección se realiza únicamente sobre los individuos dominantes de la población.

Antes del proceso de selección se clasifica la población según la adaptación de forma decreciente.

Se coge al primer individuo (el mejor) y de forma descendente se compara con el resto de la población. Aquellos individuos que están dentro de su radio de nicho (individuos dominados) son eliminados.

El proceso continua con el segundo individuo de la clasificación que aún no haya sido eliminado, y eliminará los individuos dominados por el. Así sucesivamente.

Clearing: Pérowski, A. (1996). Clearing procedure as a niching method for genetic algorithms. In *Proc. 1996 IEEE* tengamos los dominantes de cada nicho y con ellos se realizará la selección. *Int. Conf. Evolutionary Computation, Nagoya, Japan, 798-803.*

MODELOS DE AGs MULTIMODALES

■ Clearing:

Proceso:

Ordenar P de mejor a peor

for i=0 to N-1

{

if (Fitness (P[i])>0)

{

NumGanadores=1

for j=i+1 to N-1

if (Fitness (P[j])>0) and (Distancia(P[i],P[j])< σ)

{

if (NumGanadores<=Kappa)

NumGanadores ++

else

Fitness(P[j])=0

}

}

}

Parámetros:

σ


Radio de nicho

Kappa

Número de individuos que se mantienen por nicho (los mejores)

AGs: Múltiples soluciones en problemas multimodales

- El uso de AGs Multimodales permite obtener múltiples soluciones en una única ejecución manteniendo soluciones de diferentes partes del dominio.
- El uso de técnicas de nichos es una alternativa importante para evitar la convergencia en óptimos locales, así como una herramienta importante en el desarrollo de los algoritmos genéticos para problemas multiobjetivo.



METAHEURÍSTICAS

TEMA 7. ASPECTOS AVANZADOS EN METAHEURÍSTICAS

1. INTENSIFICACIÓN VS DIVERSIFICACIÓN
2. ALGORITMOS GENÉTICOS. EXPLORACIÓN VS EXPLOTACIÓN.
ALGORITMOS CHC Y GADEGD
3. MÚLTIPLES SOLUCIONES. PROBLEMAS MULTIMODALES
4. COMENTARIOS FINALES

CONCLUSIONES: Algoritmos evolutivos y diversidad

El equilibrio entre diversidad y convergencia centra el debate en el desarrollo de nuevas propuestas de Algoritmos Evolutivos, y de las MH en general.

Actualmente hay muchas propuestas inspiradas en modelos de la naturaleza, y cuya “bio-inspiración” no refleja este necesario equilibrio.

Por ello, es necesario mejoras/adaptaciones de las propuestas algorítmicas iniciales para conseguir resultados competitivos con el “state of the art”

CONCLUSIONES: Algoritmos evolutivos y diversidad

Los algoritmos evolutivos son la metaheurística que más se ha estudiado y con mayor número de propuestas.

Presenta un mayor número de variantes y posibilidades de aplicación (multimodalidad, multi-objetivos, soluciones de longitud variable ...).

En la actualidad existen diferentes áreas de desarrollo muy activas y con propuestas que continuamente aportan nuevas soluciones a los problemas planteados: diversidad vs convergencia, alta dimensionalidad, multimodalidad, multiobjetivo, ...

METAHEURÍSTICAS

2022 - 2023



- Tema 1. Introducción a las Metaheurísticas
- Tema 2. Modelos de Búsqueda: Entornos y Trayectorias vs Poblaciones
- Tema 3. Metaheurísticas Basadas en Poblaciones
- Tema 4: Algoritmos Meméticos
- Tema 5. Metaheurísticas Basadas en Trayectorias
- Tema 6. Metaheurísticas Basadas en Adaptación Social
- Tema 7. Aspectos Avanzados en Metaheurísticas
- Tema 8. Metaheurísticas Paralelas